AI-помічник для роботи з договорами

Інтелектуальний асистент для юридичних фірм та юридичних відділів

Проблема. Юрфірма веде багатьох клієнтів, і до кожного накопичуються десятки договорів та супутніх матеріалів. Юристи вручну перечитують документи, шукають потрібні пункти, звіряють умови й тримають у голові дати продовжень і розірвань. Це повільно, дорого й піддається помилкам, а ризик — пропустити дедлайн чи нетипову умову — реальний.

Рішення. Сервіс індексує всі документи й дозволяє ставити питання природною мовою, отримуючи відповідь із посиланням на конкретний пункт договору. Документи організовані так, як працює фірма: **клієнт → справа → документи**. Кожен запит працює лише в межах обраного клієнта, а дані одного клієнта ізольовані від інших — конфіденційність і відсутність конфлікту інтересів гарантовані на рівні архітектури, а не лише налаштувань.

Ключовий принцип — довіра. Кожна відповідь супроводжується цитатою на джерело; якщо інформації в документах немає, система чесно повідомляє про це й не вигадує. Усі дії логуються, доступ розмежований за ролями. Інструмент — довідковий: остаточне рішення завжди приймає юрист.

Користувацькі сценарії

- **Юрист, швидка довідка.** «Який ліміт відповідальності у договорі з клієнтом X?» — миттєва відповідь із цитатою на §, замість перегортання 40-сторінкового договору.
- **Перевірка умов перед перемовинами.** «Який строк повідомлення про розірвання і чи є автопродовження?» — система зводить ключові умови в одну картку.
- **Контроль дедлайнів.** «Які договори продовжуються або спливають у наступному кварталі?» — список із датами й посиланнями, щоб нічого не пропустити.
- **Виявлення ризиків.** Система підсвічує відсутні стандартні пункти (напр. немає обмеження відповідальності) та нетипові умови, що відхиляються від шаблону фірми.
- **Реєстр умов.** Автоматична таблиця по всіх договорах клієнта: сторони, дати, оплата, ліміти, право, що регулює — готова до експорту.
- **Партнер, погляд на портфель.** Окрема роль із доступом до всіх клієнтів: «У скількох клієнтів governing law — Англія?», «Де ліміт нижчий за $X?» — для управління ризиками фірми (рядовий юрист бачить лише своїх клієнтів).

Чим відрізняється від звичайного чат-бота

- **Цитати на джерело** у кожній відповіді — контроль галюцинацій.
- **Ізоляція клієнтів** на рівні даних — конфіденційність і конфлікт інтересів.
- **Чесне «не знаю»** замість вигаданих відповідей.
- **Прозорі метрики якості** (точність, цитати, % галюцинацій) та аудит-лог — для регульованого середовища.

Технологічне рішення (агентний RAG)

Це не «один виклик LLM», а багатошаровий **агентний RAG-конвеєр**: кожен крок підвищує точність, керованість і безпеку. Загальний потік:

Інжест → Індексація (per-client) → Гібридний ретрівал + реранк → Агент-оркестратор → Генерація з цитатами + guardrail → Evals

- **Інжест та індексація.** Парсинг PDF/DOCX, OCR сканів, розбиття з урахуванням структури пунктів (а не «по N символів»), embeddings у векторне сховище з **окремим неймспейсом на кожного клієнта** — ізоляція на рівні даних.
- **Ретрівал — «як правильно».** Гібридний пошук (семантичний + ключові слова/BM25, важливо для юридичних термінів) + жорсткий фільтр по клієнту/справі + **реранкінг** (cross-encoder). Це витягує саме релевантні пункти, а не просто «схожий» текст.
- **Агент-оркестратор (agentic).** Маршрутизатор визначає намір запиту й викликає потрібні інструменти: ретрівал, структурну екстракцію полів, перевірку дедлайнів, флагування ризиків, порівняння з шаблоном. Складні запити вирішуються в кілька кроків, а не одним промптом.
- **Генерація.** Відповідь будується лише зі знайдених фрагментів, з цитатами на джерело; guardrail за порогом релевантності → чесне «не знаю» замість вигадки.
- **Надійність (Evals).** Метрики на тестовому наборі: faithfulness, точність цитат, релевантність, % галюцинацій; регресійні тести при кожній зміні промптів чи моделі.
- **Безпека / комплаєнс.** Ізоляція даних клієнтів, RBAC, аудит-лог, обробка без навчання на даних, опція on-prem, GDPR.

Стек: Next.js / TypeScript, Vercel AI SDK, LlamaIndex.TS (ретрівал), LangGraph (агент-оркестрація), векторне сховище (pgvector / Qdrant), evals — promptfoo. Усе на одному TypeScript-стеку; AI-ядро за потреби виноситься в окремий сервіс.

Де ще знадобиться така система

Та сама архітектура (сутність → папка документів → пошук, екстракція, дедлайни, ізоляція) повторюється в багатьох бізнесах — змінюються лише термінологія й приклади:

Вертикаль	Сутність → документи	Біль, який знімає
Бухгалтерські / аудиторські фірми	Клієнт → engagement → фінзвіти, податкові	Пошук, екстракція, дедлайни подачі
Страхові брокери	Клієнт → поліси різних страховиків	Q&A по покриттю, продовження полісів
Property management	Об'єкт/орендар → договори оренди	Ключові умови, дати продовжень, зобов'язання
Управління вендорами (будь-яка компанія)	Вендор → контракти / SLA	Автопродовження, зобов'язання, ризики
PE / VC / M&A — due diligence	Угода → data room на сотні договорів	Швидкий Q&A і флагування ризиків по угоді
Консалтинг / профі-сервіси	Клієнт → проєкт → MSA, SOW, звіти	Пошук зобов'язань, повторне використання знань
Банкінг / кредитування	Позичальник → кредитне досьє, KYC	Екстракція, моніторинг ковенантів (вищий комплаєнс)

Один продукт — кілька вивісок: для виходу в нову вертикаль змінюються лише слова й приклади документів, а ядро лишається тим самим.