Contract Intelligence

Внутрішній пілот для юридичного відділу + ТЗ на прототип демо #3

RAG / AI-агент по договорах клієнтів

Onix-Systems · версія 0.1 (чернетка) · червень 2026

Жовтим у тексті позначено пункти [ПОТРЕБУЄ РІШЕННЯ] — фінальний вибір за командою.

Зміст

1. Мета і подвійна цінність

Що будуємо: внутрішній помічник, який індексує всі договори клієнтів юрвідділу й дозволяє ставити питання природною мовою, отримуючи відповідь із цитатою на конкретний пункт договору, а також автоматично формує реєстр ключових умов.

Навіщо (подвійна цінність):

- **Внутрішня користь:** юрвідділ перестає вручну перебирати папки; швидкі відповіді, реєстр умов, нагадування про продовження/дедлайни.
- **Зовнішня користь:** той самий продукт стає флагманським демо #3 і реальним кейсом «ми зробили це для себе» для залучення клієнтів у legal / insurance / proptech на Upwork та в аутбаунді.

Принцип: спершу збираємо для себе на власних даних — це дає реальні цифри ROI та достовірний кейс замість синтетичного демо.

2. Користувачі та глядачі

- **Первинні користувачі:** співробітники юридичного відділу (пошук, перевірка умов, контроль дедлайнів).
- **Вторинні:** керівництво (звіти про ризики й продовження), акаунт-менеджери (швидкі довідки за клієнтом).
- **Глядачі демо-режиму:** потенційні клієнти й оцінювачі експертизи — їм показуємо «Inspector» з pipeline та evals.

3. Обсяг пілота (scope)

3.1. Входить у пілот (v1)

- Інжест договорів (PDF/DOCX) і побудова індексу RAG.
- Чат із відповідями + цитати на конкретні пункти/сторінки.
- Чесна відмова на поза-доменні питання («не знайдено в документах»).
- Автоекстракція реєстру ключових умов у таблицю (розділ 6).
- Базове флагування ризиків і дедлайнів (розділ 7).
- Режим «Inspector» + панель Evals (для демо й внутрішньої довіри).
- Контроль доступу: лише користувачі юрвідділу; лог запитів (audit trail).

3.2. НЕ входить у v1 (наступні ітерації)

- Автоматичне складання/редагування договорів.
- Юридичні висновки чи поради (інструмент — довідковий, рішення приймає юрист).
- Інтеграція з CRM/DMS, e-signature, нагадування поштою (пізніше).
- Багатомовність понад погоджені мови (розділ 11).

3.3. Режим роботи

Рекомендовано: живий RAG на реальних договорах, але демонстрація — на наборі з ~8–10 відрепетируваних еталонних питань (розділ 5). Це поєднує гнучкість із передбачуваністю на показі клієнту.

4. Дані

Параметр	Значення / рішення
Джерело	**[ПОТРЕБУЄ РІШЕННЯ]** звідки беруться договори (мережева папка, DMS, експорт)
Формати	PDF (зокрема скани), DOCX
Обсяг для пілота	**[ПОТРЕБУЄ РІШЕННЯ]** напр. 50–200 договорів для старту
Скани/OCR	**[ПОТРЕБУЄ РІШЕННЯ]**
Мови договорів	**[ПОТРЕБУЄ РІШЕННЯ]** укр / англ / ін.
Анонімізація для кейсу	**[ПОТРЕБУЄ РІШЕННЯ]**

5. Еталонні сценарії (golden questions)

Найважливіший розділ ТЗ. Кожен сценарій — це питання + очікувана поведінка + джерело цитати. **Список фінально узгоджує юрвідділ** — нижче чернетка-приклад.

#	Питання користувача	Очікувана поведінка / відповідь
1	Які договори автоматично продовжуються в наступному кварталі?	Список договорів + дата продовження + цитата на пункт про автопродовження.
2	У яких клієнтів ліміт відповідальності нижчий за $X?	Перелік із сумою ліміту й посиланням на відповідний пункт.
3	Який строк повідомлення про розірвання у договорі з клієнтом Y?	Конкретний строк + цитата §.
4	Які NDA спливають протягом 60 днів?	Список + дати закінчення.
5	Яке право регулює договір з клієнтом Z і де вирішуються спори?	Governing law + jurisdiction + цитата.
6	Чи є договори без пункту про обмеження відповідальності?	Список договорів, де пункт відсутній (ризик-флаг).
7	Які умови оплати у договорі з клієнтом Y?	Терміни/графік оплати + цитата.
8 (guardrail)	Яка домашня адреса директора клієнта?	«Не знайдено в наданих документах» — відповідь не формується.

[ПОТРЕБУЄ РІШЕННЯ] юрвідділ додає/коригує 5–7 питань, які для них реально найкорисніші щодня.

6. Поля реєстру (автоекстракція)

Поля, які система витягує з кожного договору у структуровану таблицю:

- Клієнт / сторони договору
- Тип договору (MSA, SOW, NDA, тощо)
- Дата підписання та строк дії
- Автопродовження (так/ні; умови)
- Строк повідомлення про розірвання
- Умови та графік оплати
- Ліміт відповідальності / liability cap
- Право, що регулює, та юрисдикція спорів
- Положення про конфіденційність / IP (так/ні)

[ПОТРЕБУЄ РІШЕННЯ] юрвідділ підтверджує/доповнює перелік полів.

7. Ризик-флаги та дедлайни

- Відсутній стандартний пункт (напр. немає обмеження відповідальності або пункту про розірвання).
- Нетипові умови (ліміт/штраф поза звичним діапазоном).
- Найближчі дедлайни: продовження, закінчення строку, вікно повідомлення про розірвання.
- Відхилення від стандартного шаблону компанії (порівняння), якщо шаблон надано.

8. Функціонал по екранах

8.1. Бізнес-погляд (для юриста)

- Поле запиту + відповідь із клікабельними цитатами (підсвічування пункту в документі).
- Чесна відмова на поза-доменні запити.
- Таблиця реєстру з фільтрами (за клієнтом, типом, дедлайном).
- Перелік ризик-флагів і найближчих дедлайнів.

8.2. Inspector (для демо й довіри)

- Pipeline запиту: ingest → retrieve → rerank → generate → cite.
- Знайдені фрагменти з relevance-скорами; видно, що реранк відкинув нерелевантні.
- Рішення guardrail (поріг релевантності).
- Латентність, токени, приблизна вартість запиту.

8.3. Evals

- Метрики на тестовому наборі: faithfulness, точність цитат, релевантність, % галюцинацій.

9. Архітектура під конфіденційність

Ключове рішення пілота. Договори клієнтів конфіденційні, тому спосіб обробки даних обираємо свідомо. Два основні варіанти:

Критерій	A. Зовнішній LLM API (no-training)	B. Self-hosted / on-prem
Суть	Хмарний LLM (напр. з вимкненим навчанням на даних), embeddings у керованому сервісі	Локальна/приватна модель + векторне сховище у вашому контурі
Швидкість збірки	**Швидко**	Повільніше
Якість відповідей	**Вища (топ-моделі)**	Залежить від моделі
Конфіденційність	Дані виходять за периметр (потрібна угода/DPA)	**Дані не залишають контур**
Вартість	Оплата за токени	Інфраструктура + підтримка
Рекомендація пілота	**Старт на А** із знеособленими/тестовими договорами	Перехід на В для бойових даних, якщо вимагає політика

[ПОТРЕБУЄ РІШЕННЯ] чи дозволяє політика компанії/клієнтів надсилати дані у зовнішній LLM API; якщо ні — одразу варіант B. GDPR і доступ лише для юрвідділу — обов'язкові в обох варіантах.

10. Технічний стек

Один розробник, повністю JS/TS (за вашою вимогою):

- **Next.js (React) —** фронт + бекенд (API routes), один репозиторій.
- **Vercel AI SDK —** оркестрація LLM, стрімінг, tool calling.
- **LlamaIndex.TS —** ретрівал по документах (чанкінг, пошук).
- **Векторне сховище —** LanceDB (embedded) для пілота; pgvector/Supabase якщо потрібен сервер.
- **Парсинг —** unpdf / pdf-parse; OCR за потреби (для сканів).
- **Evals —** promptfoo (JS-нативний, дає звіт/дашборд).
- **Хостинг —** Vercel для демо; для бойових даних — приватний хостинг у вашому контурі.

[ПОТРЕБУЄ РІШЕННЯ] хто надає LLM-ключ і бюджет на токени; цільовий хостинг для внутрішньої версії.

11. Не-функціональні вимоги

Вимога	Значення
Мова інтерфейсу	**[ПОТРЕБУЄ РІШЕННЯ]** укр / англ (для демо клієнтам США/ЄС — англ)
Цільова латентність	< 3 секунди на відповідь

Вимога	Значення
Браузер	Сучасні десктопні (Chrome, Edge, Safari)
Контроль доступу	Лише юрвідділ; кожен запит логується (audit trail)
Приватність	GDPR; дані не у URL; обробка згідно з обраним варіантом (розділ 9)

12. Критерії приймання (definition of done)

1. 8–10 еталонних питань дають правильну відповідь із коректними цитатами на пункт договору.
2. Поза-доменне питання → чесна відмова, без вигаданої відповіді.
3. Реєстр коректно витягує погоджені поля щонайменше для 90% тестових договорів.
4. Працює щонайменше 3 ризик-флаги / дедлайн-сповіщення.
5. Inspector показує знайдені фрагменти, скори й рішення guardrail.
6. Панель Evals показує 4 метрики на тестовому наборі.
7. Розгорнуто за приватним URL з доступом лише для юрвідділу; запити логуються.

13. Етапи (для одного розробника)

Етап	Тривалість	Результат
1. Інжест + ретрівал + чат із цитатами	Тиждень 1	Питання по реальних договорах з посиланнями на пункти
2. Реєстр + ризик-флаги	Тиждень 2	Таблиця умов + дедлайни/відсутні пункти
3. Inspector + Evals + полір UI	Тиждень 3	Демо-режим, метрики надійності, готовий до показу
4. Внутрішній пілот + збір ROI	Тиждень 4+	Зворотний зв'язок юрвідділу, цифри економії → кейс

Орієнтовно ~3 тижні до демо-рівня + пілотна експлуатація. Терміни уточнюються після рішень за позначками [ПОТРЕБУЄ РІШЕННЯ].

14. Перелік відкритих рішень

8. Джерело, обсяг, мови та наявність сканів у договорах (розділ 4).
9. Чи дозволено надсилати дані у зовнішній LLM API, чи лише self-hosted (розділ 9).
10. Фінальний список 5–7 питань і полів реєстру від юрвідділу (розділи 5–6).
11. Мова інтерфейсу та хто надає LLM-ключ/бюджет (розділи 10–11).
12. Чи потрібен знеособлений/синтетичний набір для зовнішнього демо (розділ 4).